AI 视频剪辑 Agent 技术实施方案

v0.5 · 自主剪辑 / 参考复刻 / 持续编辑

同一个创作工作台，两种一级任务模式

由 Agent 作出创作判断，由版本化工程与编辑执行层保证可控；用素材检索缩小候选，用真实音视频证据判断结果。

AGENT	DATA	MEDIA
Deep Agents + LangGraph 一个主控，按需辅助任务	PostgreSQL + pgvector 对象存储与工程状态分离	FFmpeg + Remotion 受控编辑、预览与导出

推荐模型组合：Claude Sonnet 5 负责创作与工具决策；Gemini 3.8 Flash 负责音视频观察。型号为接入候选，最终以项目任务实测和账号可用性为准。 [S05] [S06]

文档用途

面向创始团队、产品与研发，以及后续 Coding Agent。把架构讨论转成可评审的模块边界、数据契约、选型建议和验收顺序；不是已上线系统说明，也不是一份经过联调的代码仓库。

编制日期：2026-09-15 | 状态：推荐实施方案 / 待团队批准

依据：原始 idea 与需求 v0.3、产品与架构 v0.4，以及本轮参考复刻、技术选型和向量检索讨论。外部能力依据官方资料，核验日期同上。

READING GUIDE

决策摘要与阅读导航

默认技术路线

React / TypeScript + FastAPI + Deep Agents / LangGraph + PostgreSQL / pgvector + S3 + Celery / Redis + FFmpeg / Remotion。以模块化主后端和独立 Worker 起步，不先建设复杂多 Agent 平台。

文档与前版的关系

保留 v0.3 的“降低剪辑判断成本、默认交付成片、可继续修改”，并延续 v0.4 的 ProjectDoc、局部 Patch、锁定、版本和实际预览闭环。本版补充具体技术选择，将 Reference Remake 升级为独立技术子系统，明确向量检索不等于额外部署独立数据库。 [U1] [U2] [C1]

阅读约定：架构、表名、工具名和验收流程是本方案设计；带 [Sxx] 的第三方能力来自官方资料；示例参数用于说明，未经负载与质量测试的性能、费用和成功率不写成承诺。

要解决的问题	阅读位置
用哪些技术、为什么这样组合?	第 3–7 页：技术栈、边界、Agent、工具与异步任务
具体模型如何接入?	第 8–9 页：模型清单、Provider 与能力核验
数据库与向量检索怎么做?	第 10–11 页；第 26 页检索契约
如何保证工程不被 AI 改坏?	第 12–13 页；第 24 页工程 / Patch 示例
素材与参考复刻怎么落地?	第 14–16 页；第 25 页参考与模型配置
Skills、编辑器和渲染如何协作?	第 17–19 页
部署、风险、成本和开发顺序?	第 20–23 页；来源见第 27–28 页

先批准边界，再扩大能力

第一阶段优先 Web-first、Travel / Daily Vlog、20–90 秒成片；原始素材总时长和大小另设限额。已有模块能适配契约就保留，不因 Agent 化强制重写。目标地区、团队人数、预算和服务目标尚未给定，部署与容量属于待决策项。 [U1] [U2]

01 / TECHNOLOGY STACK

推荐技术栈与自研边界

层次	推荐起点	本项目的实现责任
工作台	React + TypeScript；新项目可选 Next.js	预览、选区、素材、对话、版本；时间线按需展开
业务后端	Python + FastAPI + Pydantic	Project Service、权限、领域校验与任务入口 [S24]
Agent	Deep Agents / LangGraph	工具与上下文、暂停恢复、预算与产品安全边界 [S01–S03]
正式数据	PostgreSQL + JSONB + pgvector	工程 / 版本 / 元数据 / 检索；不另建独立向量库 [S09] [S10]
托管选择	Supabase 可作为 PostgreSQL / 认证起点	与自建业务后端的授权一致；不等于自动安全 [S12]
媒体字节	S3 对象存储	原素材、代理、音轨、预览、导出及生命周期 [S14]
后台任务	Celery + Redis	投递、执行、重试；正式任务状态保存到 PostgreSQL [S13] [S28]
模型	Sonnet 5 + Gemini 3.8 Flash	Provider 接口、证据契约、调用评测与成本 [S05] [S06]
编辑与渲染	FFmpeg + Remotion	受控效果子集、共享时间语义与一致性测试 [S18] [S19]
观测	Langfuse + OpenTelemetry 接入	追踪模型、工具、Job、Revision，做脱敏与归因 [S23]

重点自研，而不是从底层重造

重点掌握 **ProjectDoc / Patch、素材观察与匹配、Reference Blueprint / Alignment、Skills 与审美资源组织、持续修改评测**。基础模型、数据库、编解码、任务框架和基础组件优先复用。 [U2]

若主业务已是 TypeScript，可保留现有服务，Python 承担 Agent / 分析，Node.js 承担 Remotion。只要求正式工程统一写入口，不要求为了语言统一迁移全部代码。模型与软件依赖在仓库锁版本。

02 / SYSTEM BOUNDARIES

系统分层与唯一正式状态

下表表示逻辑边界，不代表每一行都要部署为独立微服务。正式作品修改统一进入 Project Service；AI 与人工编辑不能分别维护两份时间线。

逻辑层	职责	读写对象
创作工作台	自然语言 + 选区 + 当前 revision；展示真实进度	请求、选择、预览和操作反馈
Director Agent	根据任务动态选择方法与工具	只读工程视图；提出候选修改
能力层	素材检索 / 精看、参考拆解、审片、Skills	证据、候选、引用；不覆盖正式作品
Project Service	授权、约束、校验、事务、版本提交	ProjectDoc、不可变 revision、主版本指针
执行层	异步分析、媒体处理、动态图形、预览与导出	Job、媒体 artifact、诊断与依赖
横向保障	租户隔离、持久化、预算、日志与评测	运行、费用、授权和保留策略

三类状态必须分开

作品状态：PostgreSQL 中的 ProjectDoc revision 决定现在如何剪。**执行状态：**LangGraph checkpoint 与 jobs 记录 Agent / Worker 做到哪里。**衍生状态：**检索索引、代理、缓存和预览可重建，不能反过来覆盖作品。

一次修改的最小闭环

```
当前工程 + 用户反馈
  -> 获取相关工程 / 素材 / Skill
  -> 生成候选 Patch -> 校验并保存候选 revision
  -> 按需要生成预览 -> 观看结果 / 局部修复
  -> 校验主版本未变化 -> 提交新主版本
  -> 输出来自实际差异的修改摘要
```

简单字幕修改无需完整分析全部素材；首次成片与参考复刻可能多次观察。Agent 决定创作路径，服务端限制授权、影响范围和预算。

03 / AGENT RUNTIME

Deep Agents + LangGraph 的落地方式

Deep Agents 提供工具循环、Skills、上下文卸载与辅助任务等 harness 能力，底层使用 LangGraph 运行时。LangGraph 提供 checkpoint / store 等持久化基础。选择这套组合是工程建议，不代表其能自动实现视频产品的事务与权限。 [S01] [S02]

一个主控，按需委派

Director 是唯一可请求正式提交的 Agent。参考分析、候选搜索和审片先做工具；只有任务足够独立或需要长上下文时才委派辅助 Agent。辅助任务返回证据与候选，不直接修改主工程；普通编辑无需多个角色轮流发言。

每轮上下文	应包含什么
任务	目标、两种任务模式、当前请求、可修改范围和预算
工程	最新 revision、selection、锁定规则、相关片段与人工修改
证据入口	素材目录、检索结果、可重看的时段、参考蓝图版本
方法	Skill 描述 / 按需正文、审美包、品牌规范、项目偏好
执行	最近工具结果、等待 Job、取消标志与请求序号

受控工作空间

```
/skills/       已启用 Skill 与资源，只读
/references/   参考蓝图与证据入口，只读
/project/      当前工程只读视图，不是正式 JSON 文件
/scratch/      临时分析草稿，可写但不具备正式权威
```

生产环境不挂载宿主机根目录，不默认暴露 shell、网络或数据库凭据。文件工具的路径权限不能替代自定义工具授权；官方也明确本地 shell 没有隔离。建议使用虚拟后端，代码任务进入独立沙箱。 [S03]

恢复时重新读取正式 revision 和授权，而不是只信任 checkpoint。Checkpoint 管执行连续性；明确偏好与工程约束由业务数据库管理。框架默认记忆目录不能擅自写入长期偏好。

04 / TOOL CONTRACTS

首批工具与权限契约

工具描述写清输入、输出、影响范围与失败状态。工具粒度是一组有意义的剪辑动作，而不是一个无法约束的 auto_edit，也不是每帧调用一次 API。以下均为本项目建议的接口名。

工具	产物 / 作用	必要约束
get_project_context	revision、选区、锁定与相关工程	身份由服务端注入
search_moments	带 source range 的候选列表	项目授权 + 模型 / 索引版本
inspect_media	视听观察、关键帧、证据与不确定项	受控 asset_id；不接受任意外部 URL
analyze_reference	带时间定位的参考蓝图	分析版本与参考哈希
propose_edit_patch	校验报告、候选 revision、影响范围	base_revision、稳定 ID、幂等键
render_preview	job_id，完成后返回 artifact_id	候选版本、效果配置、配额
review_preview	技术 / 审美 / 参考偏差及位置	实际预览 + 适用要求
commit_revision	主版本指针与差异摘要	比较版本、锁定、权限、确认要求
save_method_draft	待确认方法卡 / Skill 草稿	不得默认修改长期偏好

统一返回格式

```
status: ok | pending | needs_confirmation | failed
request_id / tool_call_id / base_revision
result_ref / evidence_refs / warnings
job_id / retryable / error_code
```

短工具立即返回；长工具返回 pending 与 job_id，由调度层恢复，不要求模型循环询问进度。结构化输出仍需 Pydantic / 领域校验；JSON 合法不等于素材存在、时间合法或已授权。

权限原则

素材里的字幕、参考文案、Skill 内容和模型输出都不能自授权限。服务端决定读什么、能改哪里、是否可使用生成素材、是否可产生额外费用。

05 / DURABLE JOBS

长任务、恢复与幂等

LangGraph 保存 Agent 执行上下文；Celery 执行分析、转码和渲染；PostgreSQL 保存正式 jobs 与状态。持久化 checkpoint 和队列并不自动构成“一次且仅一次”的业务执行。Celery 任务仍需幂等设计。 [S02] [S13]

建议的可靠投递协议

阶段	服务端行为
1. 创建	同一数据库事务写入 job 与 outbox 事件，提交后由 dispatcher 投递
2. 认领	Worker 校验租户、输入版本与取消状态，认领 lease 并记录 attempt
3. 执行	计算在事务外进行，写阶段产物、心跳和错误信息
4. 完成	先确认输出 artifact 完整，再持久化成功状态与完成事件
5. 恢复	恢复 Agent 前去重事件、重新读取当前 revision 与任务状态
6. 提交	旧任务可保存历史结果；只有当前授权且版本匹配的请求可前移主版本

状态机与取消

```
QUEUED -> RUNNING -> SUCCEEDED
                  -> FAILED / RETRY_WAIT
QUEUED / RUNNING -> CANCEL_REQUESTED -> CANCELLED
恢复失败或租约过期 -> 对账后重新认领，不能盲目重放副作用
```

取消是协作式协议：先记录取消请求，Worker 在安全点停止；即使远端模型调用无法立刻终止，也禁止过期结果提交。浏览器断开不等于自动取消。每个项目对主控运行做串行协调，数据库版本检查仍是最终保护。

Redis Broker 的 visibility timeout 要和真实任务、确认策略一起配置，避免长任务被重复投递；不能单纯把超时无限加长来掩盖卡死。增加数据库对账任务发现漏投、超时或卡住的 Job。 [S28]

等待 / 恢复、outbox、lease、幂等键与对账是本项目需实现的协议，不是 Deep Agents 或 Celery 的自动产品能力。框架升级前固定版本并回归故障场景。

06 / MODEL SELECTION

模型组合与接入角色

以下模型名称与输入能力已按 2026-09-15 官方页面核对；它们是推荐接入起点，不是已完成剪辑效果对比的获胜方案。先用同一组真实任务验证，再锁定生产路由。

角色	推荐模型 / API ID	责任与边界
Director	Claude Sonnet 5 claude-sonnet-5	目标、工具决策、局部编辑与组件代码；接口输入为文本 / 图像，不直接假设接受 MP4 音轨 [S05]
视听观察	Gemini 3.8 Flash gemini-3.8-flash	素材、参考和真实预览观察；官方支持视频 / 音频 / 图像输入 [S06]
语音转录	Gemini 3.5 Transcribe gemini-3.5-transcribe	语音转录、说话人与词级时间；已有达标 ASR 可保留 [S07]
文本检索	Gemini Embedding 001 gemini-embedding-001	片段描述与转录的文本向量，先验证 768 维方案 [S08]
后续视觉检索	Gemini Embedding 2 gemini-embedding-2	按构图 / 视觉参考检索时再评测；视频输入不处理内嵌音轨 [S08]

为什么采用分工

Director 通过 inspect_media 获取带来源的观察，而不是靠文字摘要想象原视频。视听模型返回具体区间、证据和不确定性；Director 结合工程、用户目标与前后关系决定怎样用。图形组件生成复用主控模型，不先增加常驻的代码模型。

不把型号写死在业务逻辑

按 director、media_observer、transcriber、embedding 等角色配置模型。保存 provider、精确 model_id、可得的模型版本、SDK / Prompt / Schema 版本与区域；切换模型不改变 ProjectDoc。正式效果测试按素材项目划分，避免同源片段跨训练 / 测试。

本版不承诺特定延迟、价格或剪辑质量。账号可用性、地区、配额、文件上传路径与 SDK 兼容性仍需真实账号验收；首期不训练自有 foundation model。

07 / PROVIDER INTEGRATION

模型适配与能力核验清单

Provider 只做适配，不持有产品真相

Model Gateway 将统一任务转换为供应商请求，负责文件传递、超时、错误、限流与用量记录。禁止把某供应商的文件 URI、会话 ID 或生成工程格式当成正式资产或 ProjectDoc 的唯一标识。

核验项	落地处理
Sonnet 参数差异	当前官方文档说明自适应思考默认开启，非默认 temperature / top_p / top_k 会报错。通用客户端不能统一强塞 temperature=0。 [S05]
视频采样	默认静态低帧率采样可能漏快速细节；按任务切换精看区间 / 采样，参考重要切点需重新确认。 [S15]
ASR 时间对齐	Transcribe 文件接口支持词级时间；Live 版本能力不同。启用词级时间 / 说话人后有额外长度和功能组合限制；分段后恢复源时间偏移。 [S07]
Embedding 配置	001 的非默认小维度按官方建议归一化；索引与查询固定同模型 / 维度 / 预处理。Embedding 2 的任务配置与 001 不同，不能机械复制字段。 [S08]
降级与切换	只在已授权地区和供应商名单内切换；能力不足则保留结果并反馈，不把抽帧分析冒充完整音画审片

返回可审计的观察

```
asset_id + source_range + analysis_version
observed_events / candidate_cut_points / audio_observations
evidence_refs / uncertainties / request_id / usage
```

模型输出的“置信度”只是提示信息，不视为已校准概率。对不存在的素材 ID、越界时间、缺证据结论做验证；歧义大时重新观察，素材确实不足时请求澄清。

上线前最小冒烟测试

真实短视频带音轨、多语言字幕、动作快速变化、长文件分段；测试工具调用、结构化输出、超时与重试、文件删除。先确定可稳定运行的路径，再启用更多供应商特性。

08 / DATABASE

数据库、媒体与索引的分工

推荐 PostgreSQL 关系表 + JSONB 保存正式领域数据，pgvector 承担素材相似检索。PostgreSQL 支持 JSONB，pgvector 是数据库扩展，不是另一个独立服务。 [S09] [S10]

数据组	建议实体	权威与生命周期
项目 / 版本	projects、project_revisions、edit_operations	不可变快照 + 主版本指针；修改幂等记录
素材 / 片段	assets、moments、transcript_segments	对象存储引用、源时间、状态、分析来源
检索	moment_text_vectors	可重建；绑定内容哈希与 embedding 版本
参考	reference_blueprints；工程内 reference_context	蓝图版本不可变；Policy / Alignment 随工程版本保存
方法 / 风格	skill_versions、style_packs、project_bindings	资源和权限独立；工程固定依赖版本
个人偏好	user_preferences、feedback_events	来源、作用域、确认与删除；不自动用于训练
运行 / 交付	agent_runs、jobs、artifacts、usage_events、outbox_events	正式任务状态与事件；结果指向指定 revision
恢复	LangGraph checkpoint tables	独立 schema / 权限和保留策略，不替代作品

三类存储

PostgreSQL：是什么、属于谁、引用哪里、处于什么版本。**S3：**真实视频、音频和衍生产物。**Redis：**队列、临时缓存与协调；故障后应能靠数据库与对象存储对账恢复。

避免重复权威

ProjectDoc 是逻辑对象，数据库 revision.document 是正式快照。若为检索拆出 reference_alignments 等表，只作为可重建读索引，携带 revision_id，不得成为第二写入口。资产删除状态与权限实时生效，旧 revision 也不能绕过。

使用 Supabase 时仍执行服务端授权与 RLS；高权限 service role 可能绕过 RLS。主键、外键、tenant_id / project_id 一致性、唯一幂等键、连接池与迁移脚本必须一并设计。 [S12]

09 / VECTOR RETRIEVAL

需要向量检索，但不另建独立向量库

选型结论

首版 PostgreSQL + pgvector 即可。向量只负责找值得精看的候选，不决定整片如何剪，也不承担正式工程、锁定或所有 Agent 记忆。

search_moments 的检索链路

```
用户 / Agent 的镜头需求
  -> 服务端限定租户、项目与可用资产
  -> 元数据过滤 + 关键词 + 向量候选
  -> 合并、去重、保持片段多样性
  -> inspect_media 精看 -> 结合前后镜头做选择
```

初期按镜头或动作片段建立文本描述向量，不是整条素材只存一个向量，也不先对每一帧建库。混合检索可将词法和语义候选融合；具体权重或排序融合方法通过项目任务测试确定。 [S11]

适合向量化	不应靠向量恢复
片段描述、转录、有意义的动作时刻	ProjectDoc、当前版本、锁定和用户明确要求
规模变大后的 Skills / 审美案例目录	当前已绑定的 Skill / 参考版本，按 ID 直接读取
后续视觉构图 / 运动候选索引	参考的镜头顺序、时长与 Alignment 映射

检索规模与升级原则

项目内数据少时先测精确向量排序；有真实瓶颈再评估 HNSW / IVFFlat。近似索引结合项目过滤可能不足返回 K 条，需测试召回、过滤和迭代扫描；不能按总向量数套一个统一迁移门槛。 [S10]

只有实测检索影响正式业务读写、需要独立扩容或无法满足延迟 / 召回目标，才考虑独立向量服务。索引可重建，避免早期同时维护多套数据库。中文关键词检索需验证分词和同义表达，不能默认英文全文检索设置适用。

验收：相关片段 Recall@K、定位可用性、租户过滤正确性、p95 检索延迟，以及精看后实际采用率。高语义相似度不等于镜头优质，最终仍做视听观察。

10 / PROJECTDOC

工程模型与时间语义

延续 v0.4：高层 edit_plan 描述意图，timeline 决定执行；两者纳入同一版本化工程。人工编辑后，过期计划可标为失效，不得按旧计划默默重建时间线。 [U2]

字段组	本版建议内容
身份 / 版本	schema_version、project_id、revision_id、parent_revision_id
目标	intent、task_mode、duration、aspect_ratio、显式约束
媒体	asset_refs、source timebase、proxy mapping、可用状态
执行	tracks、clips、音频、字幕、转场、组件与时间关系
保护	按 clip / section 定义内容、时长、位置、声音等 locks
参考	blueprint_version、remake_policy、alignment、adaptations
复现	Skill / 组件 / Renderer 版本、配置、来源与变更引用

明确区分三种时间

源素材时间：用整数 tick / timescale 或明确原始 PTS 定位。**代理时间：**转码、可变帧率规范化后维护回到原素材的映射。**输出时间：**固定项目帧率，用整数 frame；帧率可用分子 / 分母表示，不把所有素材当作同一 FPS。

区间统一采用左闭右开 [start, end)，速度定义为 source_seconds / output_seconds。恒定 2 倍速时，4 秒源素材对应 2 秒输出；变速曲线由显式时间映射实现，不以修改一个 duration 字段假装完成。音频同时保留采样率与精确时间。

渲染与分析的可复现边界

保存素材哈希、精确依赖和输出配置，确保相同工程含义可追溯。不同编解码平台不默认保证字节完全一致；模型再次推理也不保证得出同一候选。需要复现的是已提交的工程、资源与效果定义。

工程 snapshot 不内嵌大视频、完整转录或全部历史日志；通过受控引用关联。数据库迁移不能直接改写旧版本含义，应显式记录 schema 升级与兼容处理。

11 / EDIT TRANSACTIONS

局部 Patch、锁定与版本冲突

Patch 使用稳定 clip / track / section ID 和领域动作，例如 replace_clip_source、trim_clip、set_caption_style。避免靠数组位置修改，也不暴露任意 SQL 或任意 JSON 路径覆盖。

正式提交协议

步骤	必须检查或执行的内容
接收请求	服务端注入 actor / tenant；验证 project、base_revision、幂等键与内容哈希
建立候选	根据指定 base_revision 应用操作，校验素材、时间、范围、效果支持与锁定
保存 / 预览	候选快照不可变；按需要渲染或技术检查，产物引用候选 revision
原子提交	数据库事务中比较当前主版本、再次授权与校验；更新主指针、记操作与 outbox
重复 / 冲突	同幂等键同请求返回原结果；同键不同内容拒绝；过期 base_revision 不直接覆盖

事务里不调用大模型、不等待渲染、不下载媒体。长计算基于不可变候选执行；提交时通过版本比较确认假设仍成立。首版出现冲突先要求重新读取，而不是尝试不可靠的自动合并。

锁定需要精确定义

内容锁不必等于时长锁；位置锁也不等于内容锁。缩短前方镜头会使后面片段前移，即使没有替换它，也可能违反位置锁。影响范围必须包含 ripple、转场覆盖、音频尾部和跨段组件，服务端校验全部连带变化。

撤销与主版本

正式撤销建议创建“恢复到指定快照内容”的新 revision，保留完整审计；查看历史版本不改变主指针。前端未提交拖动可以局部撤销，但一旦已提交，AI 与人工都走同一恢复协议。

示例

Agent 基于 r12 编辑，用户已手动提交 r13：Agent 的候选可保留，但不能把 r12 的结果覆盖 r13。重新读取 r13，重建只影响允许区域的 Patch。

12 / MEDIA PIPELINE

素材接入、索引与定向观察

上传后逐步建立可用能力

浏览器授权后直接分片上传对象存储，业务后端只管理会话和完成校验。S3 提供 multipart upload；需要处理取消、失败分片清理和内容校验。上传完成不等于可编辑，转码和分析状态分别展示。 [S14]

阶段	建议产物	重要边界
接入	asset_id、对象版本、校验和、真实媒体元数据	检查容器 / 编码 / 时长 / 大小与解码风险
代理	播放代理、音轨、缩略图、波形、时间映射	记录旋转、色彩 / HDR、帧率与采样配置
粗理解	场景候选、转录、片段描述、质量线索	候选分析不是不可修改的事实
索引	moments + 文本向量 + 来源版本	异步更新，不改变正式时间线
精看	指定 source range 的更密画面和音频证据	确认动作完成、切点和音画关系
复用	素材哈希 + 分析版本 + 请求条件缓存	先授权，再命中；删除同步失效

PySceneDetect 可提出候选切点，librosa 可估计节拍；它们不能替代剪辑判断。视频模型先看整体，再看候选与关键转场，避免每次修改重发全部原素材。 [S16] [S17] [S15]

观察结果必须可追溯

保留 asset_id、源区间、观察粒度、关键帧 / 音频引用、模型 / 规则版本及不确定项。语义描述如“适合作结尾”是条件判断，不能作为不可逆标签。音轨单独保留，不能只用抽帧确认音乐衔接或对白完整性。

摄像机拍摄效果与后期效果分开；没有拍到的视角不能通过排序得到。素材不足可提出替代或补拍，调用生成视频必须另行授权，并记录来源与费用。

13 / REFERENCE REMAKE

参考蓝图：复刻的独立任务上下文

自主剪辑由素材与目标驱动；参考复刻由参考证据、迁移要求和素材适配驱动。共用 Director、编辑执行和 ProjectDoc，但不能只向自主剪辑 Prompt 追加一句“像这条”。 [C1]

复刻层级	保持什么	首版定位
借鉴感觉	氛围、总体节奏与审美倾向	允许重新组织结构
复刻剪法	段落、快慢变化、镜头组合与主要音画关系	推荐主入口，适配用户真实素材
逐镜对齐	在支持范围内保留镜头角色、切点、时长和效果	更严格；素材不足要明确反馈

Reference Blueprint 的三层信息

观察事实：切点、时长、画面运动、声音事件、文字时段等，带源时间与证据。**解释假设：**某段可能承担建立环境、加速或收束作用，标明分析性质。**本次要求：**由用户选择的迁移维度进入 Remake Policy，不把参考里所有元素自动复制。

建议结构

```
reference_asset_id / content_hash / analysis_version
sections[]: source_range, role_hypothesis, evidence_refs
shot_patterns[]: duration_pattern, scale, motion, relationships
audio_events[] / text_events[] / effect_requirements[]
uncertainties[] / required_capabilities[]
```

蓝图先不绑定用户素材；Remake Policy 则定义必需 / 可适配 / 不迁移维度，以及内容、音乐、品牌等资源是否获准使用。参考同款可以保留“短、短、长”的关系，而不复制原地点或人物。 [U1]

只有成片时，未必能够唯一恢复原作者的参数、插件或摄影机动作。本功能目标是得到满足所选要求、可编辑的新工程，不承诺逆向恢复原工程。

14 / REFERENCE ADAPTATION

素材适配、时间对齐与对照审片

按镜头作用与前后关系匹配

先从蓝图得到镜头角色、时长容差、运动与声音关系；再用 search_moments 找候选，inspect_media 检查真实动作区间。联合考虑整组连续镜头的重复、景别和衔接，不能每个位置独立取最高相似度。

工程对象	保存内容与约束
Remake Policy	选定维度、严格性、时长 / 音乐选择、允许适配范围
Reference Alignment	参考 section / range 到输出 clip / range 的多对多对应
Adaptation Decisions	偏离位置、原因、替代方式及是否需要用户确认
Review Findings	实际预览与参考的差异、证据、影响位置与建议修改

音画关系不能只复制秒数

同一首已获准使用的音轨可对齐原音轨位置；更换音乐时，迁移节奏组合与转折关系，并建立新的时间对应。严格锁定原切点、换音乐、所有切点卡新重音可能互相冲突，应识别冲突并遵循明确优先级。

素材缺口与能力缺口

可适配要求允许功能相似替换或小范围重组，并记录偏差；严格要求不能静默放宽。依赖真实运镜而素材缺失时，说明为什么不像，给出替代 / 补拍路径。复杂特效不支持时，不能忽略后仍称为高保真复刻。

对照审片与多轮编辑

审片分别检查 **选定参考维度的一致性、成片本身质量、技术与权限约束**，不输出未经校准的总相似度百分比。用户说“参考中间那段不像”时，通过 Alignment 定位本片对应区域；时长、音乐或镜头变化后更新相关映射或标记失效。

必须可继续修改

复刻第一版与之后的局部反馈使用相同 Patch / revision 协议。用户要求“开头保留、结尾更像”时，不重新运行整套参考拆解，不破坏已锁定片段。

15 / SKILLS & TASTE

Skills、审美资源与个人偏好

采用 Agent Skills 的 SKILL.md + 附属资源组织方式，先加载名称 / 描述，再按任务读取正文。少量精选 Skills 不依赖向量检索。标准支持方法资源的组织，不替代你们的编辑 API、授权和质量验证。 [S04] [S01]

对象	用途	保存 / 生效方式
任务 Skill	参考拆解、访谈粗剪、音乐重排等方法	有版本的 SKILL.md 与证据 / 工具依赖
Style Pack	镜头、节奏、叙事和音画审美	正反例、原则与不合适素材的替代策略
Brand Kit	字体、Logo、字幕与片尾规范	授权资源 + 参数 + 项目绑定
项目 Reference	本次借鉴 / 复刻哪些维度	Blueprint + Policy，不自动成为长期偏好
Taste Profile	用户确认的长期倾向	作用域、来源、时间、可修改和可删除

推荐资源结构

```
travel-remake/
  SKILL.md          方法、适用条件、工具使用与失败策略
  references/       带音频的视频例子与分析
  assets/           已授权字体、图形、声音资源
  components/       经审核的动态图形组件
  evals/            本项目扩展：验证样例
  manifest.json     本项目扩展：版本与依赖，不授予权限
```

第三方 Skill 导入先审核来源和依赖；执行能力由应用授予。生成代码进入独立沙箱，不读取密钥、不跨项目读素材，网络与资源受限制。

保存方法不是自动记住所有修改

用户说“以后按这种方式剪”时，先生成可编辑的方法卡，经确认保存。区分一次性反馈、项目规范、长期偏好；“同款结构模板”与“提炼审美风格”分别保存，不混成一份固定时间线。

16 / EDITING & RENDERING

受控剪辑与混合渲染路线

保持结构化 TimelineSpec；普通裁切、排序、变速、字幕与音频由可信效果实现读取。动态图形作为有时长、参数、依赖和代码哈希的组件节点，不允许每次请求重写整片任意代码。 [U2]

层次	推荐路线	验收重点
媒体处理	FFmpeg：代理、规范化、音频与预计算效果 [S18]	输入验证、参数白名单、时间映射与资源限制
预览 / 合成	优先验证 Remotion Composition + Player / 服务端渲染 [S19]	同一工程的时间、字体、声音、颜色与效果语义
动态图形	生成受限组件；复用 Remotion Skills [S21]	依赖固定、类型 / 资源校验、隔离预览
已有后端	现有 FFmpeg 导出可继续保留	通过 RendererProvider 隔离；不无条件同时维护两套效果语义

不能忽略的复用边界

Remotion Player 支持在 React 应用中嵌入并参数化视频；Editor Starter 不是完整产品，官方列明默认不含转场、关键帧动画、项目管理、自动保存与认证，且未针对手机优化。商业许可另行核对。 [S19] [S20] [S22]

先建立效果能力矩阵

首版支持：裁切 / 排序 / 时长、受限恒定变速、画幅 / crop、基础转场、字幕、音乐与环境音、简单图形。每种效果定义参数、时间和不支持行为。未支持效果明确拒绝或经确认降级；复杂蒙版和全格式专业软件无损往返后置。 [U1]

局部预览使用“受影响区间 + 转场 / 声音 handles”，按依赖失效缓存。所有预览与导出绑定 revision、Renderer 和配置版本。两个后端都读同一 JSON 不等于一致，必须用真实媒体回归确认。

对于沙箱生成的任意组件，不直接在主站同源执行；采用隔离域 / 沙箱预览或先烘焙视频，明确可编辑参数与可编辑性损失。

17 / FRONTEND & API

工作台状态与首批 API

工作台以预览、对话和选区为主；素材、参考对照、版本和编辑能力按需展开。React / TypeScript 维护交互状态，正式 revision 由服务端确认；不让本地缓存成为另一份权威工程。

接口草案	用途 / 返回
POST /projects/{id}/uploads	创建授权上传会话；返回对象存储上传信息
POST /assets/{id}/complete	确认上传并校验，进入处理 Job
GET /projects/{id}	当前 revision、任务摘要、资源与权限视图
POST /projects/{id}/runs	发送目标 / selection / base_revision，返回 run_id
GET /runs/{id}/events	SSE 进度与结果；事件 ID 可用于断线恢复
POST /runs/{id}/cancel	设置取消意图；不承诺远端调用瞬间终止
POST /projects/{id}/patches	人工 / AI 共用候选修改协议
POST /projects/{id}/commits	提交已校验候选，检查 base_revision 与授权
POST /projects/{id}/exports	导出指定 revision；返回 job_id
GET /jobs/{id}	查询正式 Job / artifact / 错误信息

事件与状态一致性

建议业务事件：run.started、tool.pending、preview.ready、revision.committed、run.needs_confirmation、run.failed。每条事件带 project / run / revision / event_id；前端按版本和事件去重，断线后重新读取快照，不能把旧预览显示为最新版。

用户拖动可先本地乐观预览，提交后根据服务端结果确认或回滚。新用户请求可取消 / 取代旧 Agent 任务；已经提交的版本不能因旧任务晚完成被覆盖。

主站 API 不接收前端传来的任意租户身份或对象存储路径。上传、分析、渲染均加认证、授权与配额；只展示真实操作摘要，不将模型内部推理当作产品进度或审计依据。

18 / DEPLOYMENT

部署拓扑与代码组织

从四组进程开始

进程 / 服务	部署职责
API 服务	认证、项目 / revision、上传、提交、Job 与事件入口
Agent Worker	Deep Agents / LangGraph 运行、工具适配、恢复与预算
媒体 Worker	转码、粗分析、音轨、索引与定向观察任务
渲染 Worker	Node.js / Remotion + FFmpeg；按资源需求独立扩缩
托管基础设施	PostgreSQL / pgvector、Redis、S3、密钥与日志

Web-first 海外部署可从 Docker + ECS / Fargate 起步；Fargate 提供托管容器执行。具体区域、CPU / 内存、任务并发与临时盘空间根据基准测量，不在缺乏样本时预设成本或吞吐。 [S25]

建议单仓库目录

```
apps/web/              React / TypeScript 工作台
services/api/          FastAPI 与 Project Service
services/agent/        Director、上下文、工具与模型适配
workers/media/         转码、分析、检索索引
workers/render/        Node.js / Remotion 与媒体合成
packages/contracts/    Schema、生成的 TS 类型与测试夹具
skills/                已批准方法与审美资源
infra/                 环境、迁移、部署和恢复脚本
tests/                 契约、集成、媒体回归与端到端测试
```

Pydantic / JSON Schema 作为协议来源，TypeScript 类型由同一来源生成并做快照检查。数据库迁移、模型路由、Renderer 和 Skill 依赖分别锁定；先做开发 / 测试 / 生产环境隔离，不先引入 Kubernetes。

大陆路线保持相同领域模型；Qwen3.8-Max / Flash 为候选，官方页面支持视频等输入，音轨能力需独立验证。目标区域、服务与资源条款另行选定，不默认跨区故障转移。 [S26] [S27]

19 / SECURITY & OPERATIONS

安全、隐私与故障恢复

边界	首版必须实现的机制
租户隔离	查询、向量检索、缓存和 Worker 输入都验证 tenant / project；不可只靠对象键前缀
数据库权限	应用最小权限 + RLS / 服务端授权；高权限后台密钥单独控制 [S12]
非可信内容	参考字幕、转录、Skill 与代码按来源分级；不执行其中的越权指令
媒体风险	限制文件体积 / 时长 / 解码资源；更新解码依赖；禁止任意远程下载与内网 URL
代码与依赖	生成组件沙箱执行；默认无密钥 / 无外网；批准依赖、配额与超时
数据生命周期	原素材、代理、索引、供应商文件、日志和备份分别定义保留 / 删除流程
训练授权	当前项目处理、个人偏好保存、跨用户训练分别授权，默认不混用
恢复	数据库备份与恢复演练；对象版本 / 生命周期；Job 对账、死信与人工重试

删除与可复现性发生冲突时

删除请求先让资产不可访问，再清理代理、向量、缓存和供应商副本；备份按保留策略到期清理。历史工程可以保留“资源已删除”的引用与审计，但不能因为要复现就悄悄保留未获准媒体。导出前再次检查资源状态。

上线前审核，而不是凭架构宣称合规

本页是工程控制建议，不构成合规认证。目标地区、用户素材处理条款、供应商数据使用与保留、音乐 / 字体 / 图形许可和商业 SDK 许可都需要专项确认。参考分析授权不自动覆盖参考画面、音乐或品牌资源的导出使用。[U1] [S22]

故障底线

保留最近可用版本；分析失败不能清空工程；旧任务不得覆盖新版本；服务端不支持的效果必须明确显示，而不是静默忽略。

20 / OBSERVABILITY & EVALUATION

观测、成本与质量验证

建议 Langfuse 连接模型 / 工具链路，结合任务日志关联到 request_id、run_id、job_id、project_id、revision 和 artifact。官方提供追踪与评测能力；媒体、凭据和敏感转录进入日志前应脱敏。 [S23]

成本按任务阶段归因

```
项目成本 = 首次素材分析 + 参考分析
          + 每轮 Agent / 模型观察 + 局部预览
          + 最终导出 + 存储 / 流量 + 重试 / 取消损耗
```

原始素材总时长与成片时长分开统计。给每次运行设置模型调用、观察总时长、候选数量、渲染时长和费用预算；达到上限保留可用结果并停止 / 询问。分析缓存以授权、内容哈希、模型 / Prompt / Schema / 采样配置为键。

评测层	需要记录的指标 / 场景
检索	相关片段 Recall@K、时间定位、过滤正确性、p95 延迟
工程	锁定、越界、撤销、五轮修改、人工介入、并发与重复投递
剪辑质量	同素材盲评：镜头选择、叙事、节奏、音画关系；保留分歧
参考复刻	只评选定维度：结构 / 节奏等一致性 + 成片本身质量
体验与经济性	首个可用预览、满意轮数、修改 p50 / p95、失败率、每项目成本

对照设计

先比较同一组素材的基础工具 Agent、加 Skills / 审美包、加实际预览修复；参考模式再比较直接参考 Prompt 与 Blueprint / Alignment。报告质量收益和额外成本，不把模型自评分当作用户偏好。训练与调参按原始项目分割，保留原始投票。 [U2]

工程门槛采用明确测试用例；审美、延迟、成本阈值先测基线再由团队批准。本版没有这些指标的实测结果，不给未经依据的成功率或月成本数字。

21 / DELIVERY PLAN

开发顺序与放行门槛

阶段	交付内容	进入下一阶段的条件
A 工程内核	上传 / 代理、ProjectDoc、Patch、锁定、版本、基础预览	无需大模型也能连续修改 / 撤销；人工与 AI 共用协议
B Agent 接入	Director、关键工具、模型 Provider、Jobs / 恢复、精选 Skills	自主剪辑和参考模式都能形成可编辑草稿，失败可恢复
C 参考与审美闭环	Blueprint、Policy、Alignment、素材适配、实际预览修复	选定维度可对照；缺口可解释；盲评与成本有真实改善证据
D 内测 / 个性化	方法卡、明确偏好、运行预算、日志、删除与恢复演练	权限 / 版本 / 幂等测试通过，团队批准体验和成本门槛

必须通过的连续场景

生成第一版 → 只改中间 → 锁定开头 → 用户手动改一次 → AI 继续改结尾 → 撤销 → 根据参考局部调整 → 导出。整个过程都基于同一工程版本体系，而不是生成多个失去关联的 MP4。

测试 ID	失败注入 / 验收点
E01 / E02	过期 base_revision 被拒绝；同幂等键重试不重复修改
E03 / E04	保护位置不被 ripple 间接改变；撤销后视听与工程一致
E05 / E06	Worker 重启、重复投递可恢复；旧预览不覆盖新版本
E07 / E08	参考音乐冲突明确反馈；素材不足不自动生成或越权使用
E09 / E10	跨租户检索 / URL / 缓存全部被阻断；删除索引与媒体同步失效

下次评审只需先定下的事情

目标地区与首批用户；典型素材规模；最小效果子集；模型账号与配额；Remotion 路线的兼容 / 许可测试；ProjectDoc / Patch schema；延迟与成本基线。不要用“先接更多模型”替代工程内核和真实剪辑样本。

以上是依赖与验收顺序，不是工期或团队人数承诺。原架构中的专用 Taste Critic、复杂多 Agent、开放市场、专业 NLE 往返均按收益证据后置。 [U2]

APPENDIX A / DOMAIN EXAMPLES

ProjectDoc 与 Patch 示例

下例是协议草案，不是完整生产 Schema；所有 ID 为示例。输出 30 FPS，源时基为 1/1000 秒；区间左闭右开。

```
{
  "schema_version": "0.5", "project_id": "p01",
  "revision_id": "r12", "parent_revision_id": "r11",
  "intent": {"task_mode": "reference_remake", "target_seconds": 45},
  "timeline": {
    "fps": {"num": 30, "den": 1},
    "clips": [{
      "clip_id": "c17", "asset_id": "a01",
      "source": {"start": 12000, "end": 16000, "timescale": 1000},
      "output": {"start_frame": 240, "duration_frames": 120},
      "playback_rate": {"num": 1, "den": 1}
    }]
  },
  "locks": [{"target_id": "intro",
    "protect": ["content", "position", "duration"]}],
  "reference_context": {
    "blueprint_version": "bp03", "policy_id": "rp02",
    "alignment_version": "al12"
  },
  "dependencies": {"skill_version": "travel-remake@1",
    "renderer_version": "validated-build-id"}
}
```

为了缩短示例，仅展示一段 clip。policy_id / alignment_version 指向同一 revision 中的完整参考上下文或不可变关联记录，不代表另一个可覆盖工程的权威状态。

```
{
  "project_id": "p01", "base_revision": "r12",
  "idempotency_key": "request-42-edit-1",
  "scope": {"target_ids": ["c17"], "ripple": false},
  "operations": [{
    "op": "replace_clip_source", "clip_id": "c17",
    "asset_id": "a02",
    "source": {"start": 8000, "end": 12000, "timescale": 1000},
    "preserve": ["output_position", "output_duration"]
  }]
}
```

该 Patch 只替换 c17 的 4 秒源区间，保留输出位置与时长。actor / tenant 从服务端身份获得，不相信模型自报。提交前仍检查 a02 授权、时长、锁定、效果和主版本。

APPENDIX B / REFERENCE & MODELS

参考映射与模型配置示例

以下为独立示例：c31 / c32 / c33 分别占 15 / 15 / 30 帧。模型配置需通过 API / SDK 冒烟测试，字段不直接等于厂商请求参数。

```
reference_context:
  blueprint_version: bp03
  policy:
    mode: remake_editing
    preserve: [section_order, duration_pattern]
    adapt: [shot_content, local_duration]
    exclude: [reference_text, reference_brand]
    music_policy: user_authorized_track
    allow_generated_footage: false
  alignments:
    - reference_section_id: ref_s03
      reference_range: {start: 2000, end: 4000, timescale: 1000}
      output_clip_ids: [c31, c32, c33]
      output_range: {start_frame: 240, end_frame: 300}
      relation: short_short_long_pattern
  adaptations:
    - reference_section_id: ref_s03
      reason: required_camera_motion_unavailable
      action: replace_with_supported_cut
      status: needs_confirmation
```

按角色路由，不把单一型号写进领域模型

```
model_routes:
  director:
    provider: anthropic
    model_id: claude-sonnet-5
  media_observer:
    provider: google
    model_id: gemini-3.8-flash
  transcriber:
    provider: google
    model_id: gemini-3.5-transcribe
  text_embedding:
    provider: google
    model_id: gemini-embedding-001
    output_dimensions: 768
    normalize: true
policy:
  region_profile: approved-region-profile
  cross_region_fallback: false
  generated_media_requires_confirmation: true
```

模型 ID 与模态见官方来源 [S05–S08]。部署凭据仅进入密钥管理，不写进配置示例、Skill 或 Agent 文件系统。query / document 使用匹配的检索任务配置；模型 / 维度升级时重建索引并灰度切换。

APPENDIX C / RETRIEVAL CONTRACT

片段索引化索示例

建议将 moments 与向量表分开：moments 持有片段身份、源区间和描述；moment_text_vectors 保存某次分析版本对应的文本向量。向量表是可重建索引，不保存正式锁定和剪辑状态。

建议字段	含义
tenant_id / project_id / moment_id	授权范围与片段引用；建立一致性约束
embedding_model / embedding_version	模型与索引预处理版本，查询必须匹配
description_hash / source_analysis_version	描述与分析来源；变化后重建
embedding vector(768)	单一模型配置的向量列；不同空间不混搜
status / created_at	仅检索 ready、未删除且已授权素材

先做带过滤的精确检索基线

```
-- SQL 片段：表与外键需通过正式 migration 建立。
-- :tenant_id / :project_id 由已授权服务端上下文绑定。
SELECT m.moment_id, m.asset_id,
       m.source_start, m.source_end, m.timescale,
       1 - (v.embedding <=> CAST(:query_vector AS vector)) AS score
FROM moments m
JOIN moment_text_vectors v
  ON v.moment_id = m.moment_id
 AND v.tenant_id = m.tenant_id
 AND v.project_id = m.project_id
JOIN assets a
  ON a.asset_id = m.asset_id AND a.tenant_id = m.tenant_id
 AND a.project_id = m.project_id
WHERE m.tenant_id = :tenant_id
  AND m.project_id = :project_id
  AND a.status = 'ready' AND m.status = 'ready'
  AND v.embedding_model = :embedding_model
  AND v.embedding_version = :embedding_version
  AND v.description_hash = m.description_hash
  AND v.source_analysis_version = m.analysis_version
  AND v.status = 'ready'
ORDER BY v.embedding <=> CAST(:query_vector AS vector)
LIMIT :candidate_limit;
```

服务端校验 candidate_limit 上限、向量维度 / 非零值与模型一致性，返回 asset_id + source range + score。score 是检索量，不是审美质量或已校准概率。SQL 没有字符串拼接；权限检查仍不能由 WHERE 中的用户输入替代。

上述基线假设尚未配置近似向量索引；增加 HNSW 后检查执行计划、过滤召回与尾延迟，再与精确结果对照。中文词法检索与向量结果可融合，但不盲目复用一个总权重。 [S10] [S11]

SOURCES / 1 OF 2

依据与官方参考资料

官方页面核验日期：2026-09-15。标题可点击访问。公开文档证明接口 / 功能描述，不证明本产品已集成、已实测或在所有账号 / 地区均可用。

[U1] AI 视频剪辑项目说明 v0.3
用户提供原始需求；重点参照第 3–6、8–9、11–13 页。

[U2] AI 视频剪辑 Agent：产品与技术架构方案 v0.4
当前会话生成文档；重点参照第 6–13、15–19 页。

[C1] 本轮架构与技术讨论
参考复刻、具体技术选型与向量检索解释；本版将其工程化。

[S01] Deep Agents overview
harness、工具、Skills、辅助任务与 LangGraph 关系。

[S02] LangGraph persistence
checkpoint / store、持久化与恢复边界。

[S03] Deep Agents backends
虚拟文件系统、本地 shell 与安全边界。

[S04] Agent Skills specification
SKILL.md、资源组织与按需加载。

[S05] Claude Sonnet 5 overview
模型 ID、文本 / 图像输入与参数变化。

[S06] Gemini 3.8 Flash
模型 ID、视频 / 音频输入、工具与结构化输出。

[S07] Gemini 3.5 Transcribe
文件 / Live 差异、时间标注和功能限制。

[S08] Gemini embeddings
Embedding 001 / 2、维度、任务配置与视频音轨限制。

[S09] PostgreSQL JSON types
JSONB 及其数据库表示能力。

[S10] pgvector official repository
精确 / 近似检索、过滤与索引策略。

[S11] Supabase hybrid search
词法与向量候选融合的实现参照。

[S12] Supabase row level security
RLS、应用授权与 service role 注意事项。

SOURCES / 2 OF 2

执行、媒体与部署参考

[S13] Celery tasks
任务重试、确认和幂等设计。

[S14] Amazon S3 multipart upload
分片上传、完成与清理。

[S15] Gemini video understanding
视频输入、静态 / 定向探索和采样边界。

[S16] PySceneDetect detectors
候选镜头切换检测。

[S17] librosa beat_track
节拍位置与速度估计。

[S18] FFmpeg filters
媒体、音频与合成的执行能力。

[S19] Remotion Player
React 内预览与参数化；渲染接口入口。

[S20] Editor Starter: features not included
转场、关键帧、项目、认证、移动端等边界。

[S21] Remotion Agent Skills
动态图形、时间、声音、字幕与可编辑性资源。

[S22] Remotion license
商业使用条款的核对入口；本文不做许可结论。

[S23] Langfuse documentation
追踪、评测与观测能力。

[S24] FastAPI documentation
Python API、类型与数据校验框架。

[S25] AWS Fargate for Amazon ECS
托管容器部署候选。

[S26] Qwen3.8-Max 模型信息
大陆路线主控 / 多模态候选，不代替账号测试。

[S27] Qwen3.8-Flash 模型信息
大陆路线观察候选，音轨能力需另验。

[S28] Celery: Using Redis
Broker visibility timeout 与重复投递风险。

维护说明：在正式开发时记录依赖锁文件、供应商账号可用性测试与基准结果；模型或框架升级后重新运行契约、媒体一致性与五轮编辑测试，不依赖本版静态型号永久有效。